



Tecnológico de Monterrey

Campus Querétaro

Plan de Monitoreo y Mantenimiento

Gamaliel Marines Olvera	A01708746
Uri Jared Gopar Morales	A01709413
José Antonio Miranda Baños	A01611795
María Fernanda Moreno Gómez	A01708653
Oskar Adolfo Villa López	A01275287
Luis Ángel Cruz García	A01736345

Inteligencia artificial avanzada para la ciencia de datos II
Grupo 501

Índice

Índice.....	1
Introducción.....	2
Aspectos Dinámicos del Ambiente.....	2
Monitoreo de la Precisión.....	2
Preparación del dataset.....	3
Entrenamiento del modelo.....	3
Generación de predicciones.....	3
Generación de datos reales.....	3
Comparación de resultados.....	3
Gráfica de Loss (Pérdida).....	6
Gráfica de Accuracy (Precisión).....	6
¿Cuándo debe dejar de ser usado el resultado?.....	9
Cambios significativos en el entorno.....	9
Nueva evidencia o datos disponibles.....	10
Criterios para dejar de usar los resultados.....	10
¿Qué pasa si un resultado no puede seguir siendo usado?.....	10
¿Los objetivos de negocio del uso del modelo cambian a través del tiempo?.....	11
Factores que pueden influir en el cambio de objetivos.....	11
¿Cómo manejar los cambios en los objetivos de negocio?.....	12
Ejemplos de posibles cambios en los objetivos.....	13
¿Dudas adicionales?.....	13

Introducción

En este documento se redactará nuestro plan de monitoreo y mantenimiento de nuestro modelo de CNN, el cual tiene como principal objetivo garantizar la sustentabilidad del modelo, asegurando que siga cumpliendo con los objetivos de negocio.

En dicho plan se basará en principios claros, los cuales aseguran que el modelo siga entregando resultados precisos y útiles para la toma de decisiones. Incluyendo estrategias para identificar cambios en el entorno, evaluar periódicamente la precisión del modelo, definiendo los criterios para su actualización o reemplazo y establecer las acciones específicas cuando los resultados no sean adecuados.

Aspectos Dinámicos del Ambiente

El ambiente donde se implementa el modelo está sujeto a cambios constantes que pueden afectar su desempeño. Factores como las condiciones de iluminación, el estado de las camas, la posición de las cámaras o incluso el comportamiento de las vacas pueden alterar los datos recolectados. Es crucial identificar y documentar estos cambios para asegurar que el modelo siga siendo relevante y funcional en el entorno real.

Por ello, se debe:

- Monitorear cambios en las condiciones del establo (iluminación, estructura de las camas, cantidad de vacas, comportamiento).
- Evaluar la calidad de las imágenes capturadas por la cámara (resolución, claridad).
- Registrar y analizar patrones cambiantes en los datos del comportamiento de las vacas, como horarios de descanso.

Cada que haya un cambio como estos, se debe monitorear la precisión del modelo para verificar que los resultados del modelo sigan siendo vigentes. En la parte de *Monitoreo de la Precisión* se explica cómo se mide la precisión. Se recomienda que un usuario experto en ciencia de datos haga las pruebas de precisión descritas en dicha parte, sin embargo, si no se cuenta con un usuario con dichos conocimientos, manda un correo a tc.solutions.ia@gmail.com donde nos solicites el apoyo para correr las pruebas de precisión en el modelo entregado.

Monitoreo de la Precisión

La precisión del modelo es esencial para garantizar la utilidad de los resultados. Monitorear su desempeño de manera periódica permite detectar desviaciones a tiempo y tomar acciones correctivas. Esto asegura que el modelo mantenga niveles de precisión aceptables para las decisiones que dependen de sus predicciones.

¿Cómo se va a monitorear la precisión?

1. Implementar un conjunto de imágenes de validación periódicas (cada bimestre aproximadamente) con etiquetas clasificadas manualmente.
2. Calcular las métricas de desempeño, el código del modelo ya contiene el código que imprime la matriz de confusión, la gráfica de pérdida (loss) y la gráfica de precisión (accuracy). Se recomienda de igual manera correr la métrica de “Accuracy promedio por cama”, pues esta métrica nos ayuda a ver que tan bueno es el modelo para predecir en las diferentes camas y así verificar que no haya desbalance entre camas por la proporción de imágenes que hay en cada estado de la cama: “cama vacía”, “vaca acostada” y “vaca de pie”. Para realizar dicho promedio por cama se realizan los siguientes pasos.

Preparación del dataset

Inicialmente, necesitamos dividir correctamente nuestro dataset etiquetado, que contenga la distribución de las camas (A, B y C) y las posiciones correspondientes: vaca parada, vaca acostada o cama vacía. Este dataset se guarda en formato CSV, ya que será utilizado como referencia para comparar las predicciones de nuestro modelo. Y debemos guardar nuestro dataset sin realizar las divisiones, este lo ocuparemos para realizar las comparaciones entre real y predicciones.

Entrenamiento del modelo

Utilizamos la arquitectura SimpleCNN para entrenar el modelo con los datos. Una vez completado el entrenamiento, los mejores pesos del modelo se guardan en un archivo con formato .pth.

Generación de predicciones

Con la ayuda del script generate_csv.py, utilizamos el modelo entrenado para generar predicciones sobre las imágenes del dataset que no fue clasificado. Este proceso genera un archivo CSV con las predicciones realizadas por el modelo.

Generación de datos reales

Ocuparemos después el mismo script de generate_csv.py, pero en este caso lo usaremos para nuestro dataset clasificado, esto para que nos genere el csv con las clasificaciones correctas que existen en las imágenes.

Comparación de resultados

Al finalizar, contamos con dos archivos CSV:

- Uno que contiene las etiquetas verdaderas del dataset (clasificado manualmente).
- Otro que contiene las predicciones del modelo.

Con la ayuda de nuestro script `accuracy.py` seremos capaces de poder realizar las comparaciones de real vs predicción y este nos dará la precisión que tiene cada cama con la realidad.

3. Comparar los resultados actuales del modelo con los datos históricos de las mismas métricas.

Las métricas actuales del modelo, con las imágenes etiquetadas y que sirvieron para entrenar el modelo, son las siguientes:




Imagen 1: Matriz de confusión del tercer modelo. (0: Cama vacía, 1: Vaca acostada, 2: Vaca de pie)

La matriz de confusión nos ayuda a valorar cómo de bueno es un modelo clasificación basado en

aprendizaje automático. Muestra la cantidad de veces que una clase es confundida con otra, lo que permite identificar errores como las clases con menores rendimientos y así crear planes para solucionar dicho problema.

La matriz está organizada en un formato de cuadrícula donde:

- **Filas:** Representan las clases verdaderas (los valores reales de las etiquetas en el conjunto de datos).
- **Columnas:** Representan las clases predichas por el modelo.

Cada celda de la matriz contiene un valor que indica la cantidad de instancias para una combinación específica de valores reales y predichos:

- **Diagonal principal (de arriba a la izquierda hacia abajo a la derecha):** Contiene los casos donde el modelo acertó (predicciones correctas).
- **Fuera de la diagonal:** Contiene los casos donde el modelo se equivocó (predicciones incorrectas).

Siendo así, en el modelo inicial se tienen:

- 1314 aciertos en “cama vacía” de un total de 1323 (**99%** de los casos acierta).
- 354 aciertos en “vaca acostada” de un total de 394 (**89%** de los casos acierta).
- 38 aciertos en “vaca de pie” de un total de 60 (**63%** de los casos acierta).

En este caso, el modelo demuestra un excelente desempeño al identificar camas vacías y vacas acostadas, lo que resulta fundamental para los objetivos del análisis. Aunque su rendimiento para la clase "vaca de pie" es menor, esto no representa un problema significativo, ya que son pocos los casos en los que una vaca está de pie en su cama. Además, las confusiones principales ocurren con la clase "cama vacía", que no afecta directamente los hallazgos críticos, pues el enfoque principal está en detectar correctamente cuándo una vaca está acostada en la cama. Por lo tanto, este comportamiento del modelo es aceptable dentro del contexto del proyecto.

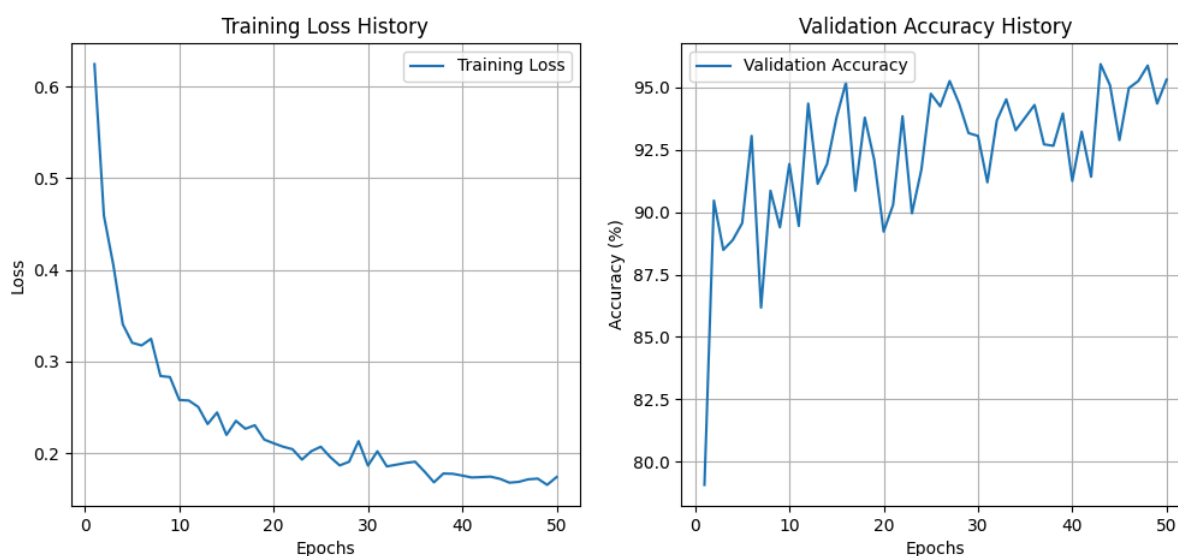


Imagen 2: Gráfico de pérdida de training y de precisión en el conjunto de validación del modelo final

Las gráficas de pérdida y precisión son herramientas visuales clave para evaluar el desempeño de un modelo de aprendizaje automático durante su entrenamiento y validación. Ayudan a entender si el modelo está aprendiendo correctamente y si se está adaptando a los datos de manera adecuada

Gráfica de Loss (Pérdida)

La pérdida es una métrica que mide qué tan lejos están las predicciones del modelo de los valores reales. En términos simples, es un indicador de "qué tan mal" está haciendo el modelo.

La manera de interpretar la gráfica es la siguiente:

- **Disminución constante:** Una línea de pérdida que disminuye a lo largo de las épocas indica que el modelo está aprendiendo y ajustándose mejor a los datos de entrenamiento.
- **Estancamiento:** Si la pérdida deja de disminuir, el modelo ha llegado a un punto donde ya no mejora con los datos actuales.
- **Aumento o inestabilidad:** Un aumento en la pérdida puede ser señal de **sobreajuste** (overfitting), donde el modelo se adapta demasiado a los datos de entrenamiento, sacrificando su capacidad para generalizar.

En el gráfico proporcionado, la curva de pérdida disminuye de manera constante durante las primeras épocas y se estabiliza hacia el final, lo cual es un buen indicador de que el modelo está aprendiendo de manera adecuada sin sobreajustarse.

Gráfica de Accuracy (Precisión)

La precisión mide el porcentaje de predicciones correctas del modelo en un conjunto de datos. Es una métrica intuitiva para evaluar qué tan bien clasifica el modelo.

La manera de interpretar la gráfica es la siguiente:

- **Aumento constante:** Una curva de precisión que aumenta con las épocas indica que el modelo mejora su habilidad para clasificar correctamente.
- **Estancamiento:** Una línea que deja de subir sugiere que el modelo ha alcanzado su capacidad máxima de aprendizaje con los datos actuales.
- **Discrepancias entre entrenamiento y validación:** Si la precisión en el conjunto de validación (datos nuevos) es mucho menor que la del entrenamiento, puede indicar **sobreajuste**.

En el gráfico de precisión proporcionado, se observa que la precisión del conjunto de validación se estabiliza alrededor del 95%, lo cual es un excelente resultado. Esto indica que el modelo está generalizando bien a datos nuevos.

Además de las gráficas obtenidas en el entrenamiento del modelo (que son las dos imágenes anteriores), se recomienda de igual manera obtener la de “Accuracy por cama” (anteriormente ya se explicó cómo obtener esta métrica). Los datos iniciales para esta métrica con el modelo entregado son los siguientes:




Imagen 3: Gráfico que explica la distribución de la Cama A




Imagen 4: Gráfico que explica la distribución de la Cama B




Imagen 5: Gráfico que explica la distribución de la Cama C

```
Precisión por cama: {'A': 0.942322286870731, 'B': 0.9509233493549203, 'C': 0.9855805717176828}
Precisión global: 95.96%
```

Imagen 6: Explicación del accuracy por cama

Las imágenes anteriores muestran la distribución de categorías reales y predichas para las camas, con tres categorías principales:

- Cama vacía
- Vaca parada
- Vaca acostada

Las barras azules representan los valores reales, es decir, la cantidad de veces que realmente ocurrió cada categoría.

Las barras naranjas muestran las predicciones realizadas por el modelo.

La comparación entre estas barras te ayuda a ver qué tan bien está prediciendo el modelo para cada categoría.

Para la categoría cama vacía, las predicciones están muy cerca de los valores reales, lo que indica que el modelo es muy preciso en esta categoría.

Para las categorías vaca parada y vaca acostada, aunque hay menos datos, las predicciones también se alinean bastante bien con los valores reales, sin embargo, debemos cambiar el modelo al momento de que se refleje un accuracy de menos de 80% en la precisión global.

¿Cuándo debe dejar de ser usado el resultado?

Es fundamental identificar cuándo los resultados del modelo ya no son confiables o útiles para el objetivo del negocio. Esto permite garantizar que las decisiones basadas en el modelo sigan siendo precisas y relevantes. A continuación, se detallan las condiciones y criterios clave para determinar cuándo dejar de usar los resultados:

Precisión por debajo del umbral aceptable

- Si la **precisión global del modelo** cae por debajo del 80%, significa que el modelo ya no clasifica adecuadamente las imágenes en las categorías deseadas.
- La precisión por cama (accuracy por cama) también es crítica. Si alguna cama refleja un desempeño muy bajo (por ejemplo, menos del 70% de aciertos en cualquier categoría), se deben tomar medidas inmediatas.

Cambios significativos en el entorno

- Si las condiciones físicas del establo cambian, como una nueva disposición de las camas, modificación de la iluminación, o reemplazo de cámaras, los datos recolectados pueden no ser consistentes con los datos utilizados para entrenar el modelo.

- Cambios en el comportamiento de las vacas (por ejemplo, nuevas razas, cambios en la alimentación o manejo) también pueden afectar la relevancia del modelo.

Nueva evidencia o datos disponibles

- Si se recolectan datos que reflejan patrones significativamente diferentes a los utilizados para entrenar el modelo, puede ser necesario actualizar el modelo para incluir esta nueva información.

Fallas técnicas:

- Si el modelo deja de ejecutarse correctamente en la infraestructura del socio formador o no genera resultados dentro del tiempo esperado (5 minutos por imagen), su uso debe ser revisado.

Criterios para dejar de usar los resultados

Desempeño insuficiente:

- Si las métricas como **precisión** o **accuracy por cama** están consistentemente por debajo de los umbrales definidos (ej., 80%), el modelo ya no es adecuado para el propósito.

Pérdida de relevancia:

- Si los objetivos del negocio cambian y ya no se centran en las métricas actuales (por ejemplo, priorizar la producción de leche en lugar de la ocupación de las camas), los resultados del modelo podrían volverse obsoletos.

Evidencia de sesgo o desbalance:

- Si se observa que el modelo está favoreciendo una categoría específica (por ejemplo, predice "cama vacía" con alta precisión, pero falla constantemente en "vaca acostada"), los resultados deben reevaluarse.

Desactualización tecnológica:

- Si aparecen mejores técnicas o algoritmos que pueden proporcionar resultados más precisos o eficientes, el modelo actual puede requerir reemplazo.

¿Qué pasa si un resultado no puede seguir siendo usado?

Si un resultado ya no es el adecuado, se deben tomar las siguientes acciones:

1. **Actualizar el modelo:**
 - Entrenar un nuevo modelo con datos más recientes que reflejen las condiciones actuales del entorno.
 - Implementar técnicas avanzadas, como la aumentación de datos o el ajuste de hiperparámetros, para mejorar el desempeño.
2. **Realizar ajustes al entorno:**
 - Mejorar la calidad de las imágenes capturadas ajustando la iluminación o las cámaras.
 - Recolectar datos adicionales para las categorías con menor precisión.
3. **Revisar los objetivos del negocio:**
 - Si los objetivos han cambiado, redefinir las prioridades del modelo y ajustarlo en consecuencia.
4. **Iniciar un nuevo proyecto:**
 - Si el modelo no puede actualizarse de manera eficiente, puede ser necesario desarrollar una nueva solución desde cero que satisfaga los nuevos requisitos.

¿Los objetivos de negocio del uso del modelo cambian a través del tiempo?

Sí, los objetivos de negocio pueden cambiar con el tiempo debido a diversos factores internos y externos. Por esta razón, es importante diseñar un modelo que no solo cumpla con los objetivos actuales, sino que también sea flexible y adaptable para ajustarse a nuevas prioridades del negocio. A continuación, se describen los posibles escenarios en los que los objetivos de negocio podrían cambiar y cómo abordarlos:

Factores que pueden influir en el cambio de objetivos

1. **Cambios en las prioridades operativas:**
 - Si el CAETEC decide priorizar otros indicadores clave de desempeño (KPI), como el tiempo total de rumia, la calidad de la leche o el monitoreo de estrés en lugar del uso de camas, el modelo actual podría necesitar ajustes para alinear sus resultados con los nuevos objetivos.
2. **Evolución tecnológica:**
 - La adopción de nuevas tecnologías (como cámaras de mayor resolución, sensores avanzados o herramientas de análisis en tiempo real) podría permitir un análisis más detallado o introducir nuevos objetivos, como monitorear la actividad individual de cada vaca.
3. **Cambios en las condiciones del entorno:**

- Factores como el aumento en el número de vacas, cambios en el diseño del establo o la introducción de nuevos procesos de manejo pueden requerir que el modelo entregue resultados diferentes o más detallados.

4. Actualización de metas de negocio:

- Si el CAETEC busca expandirse o diversificar su operación, puede necesitar modelos que proporcionen insights más avanzados, como la predicción de patrones de descanso o la identificación de vacas con comportamientos atípicos.

5. Retroalimentación de resultados actuales:

- A medida que el modelo entregue hallazgos, estos mismos podrían modificar la estrategia del CAETEC, cambiando el enfoque hacia otros aspectos no considerados inicialmente.

¿Cómo manejar los cambios en los objetivos de negocio?

1. Documentar los objetivos iniciales:

- Es crucial mantener un registro claro de los objetivos originales del modelo. Esto incluye los problemas que el modelo busca resolver y los indicadores que mide. Esto servirá como referencia para evaluar qué tan alineados están los nuevos objetivos con los resultados del modelo.

2. Reevaluar los objetivos periódicamente:

- Realizar revisiones periódicas (por ejemplo, cada seis meses) para confirmar que el modelo sigue alineado con las metas del negocio.
- Consultar con los responsables del CAETEC para anticipar posibles cambios en sus prioridades.

3. Flexibilidad en el diseño del modelo:

- Diseñar un modelo que pueda ser ajustado o actualizado fácilmente para incluir nuevas métricas o procesar datos adicionales en caso de que cambien los objetivos.

4. Adoptar un enfoque iterativo:

- Implementar ciclos de mejora continua en los que el modelo se ajuste y refine para satisfacer nuevas necesidades o condiciones del entorno.

5. Monitorear el impacto del modelo en el negocio:

- Medir regularmente cómo los resultados del modelo están contribuyendo a los objetivos del CAETEC. Si el impacto disminuye, puede ser una señal de que los objetivos han cambiado.

Ejemplos de posibles cambios en los objetivos

A continuación, se presenta un ejemplo de lo que se pudiera hacer si se cambiara el objetivo de negocio:

- **Objetivo inicial:** Maximizar la ocupación de camas por vacas acostadas para optimizar la rumia y mejorar la producción de leche.
- **Nuevo objetivo:** Monitorear patrones de descanso individuales para identificar vacas con problemas de salud o estrés.
- **Acción requerida:** Ajustar el modelo para realizar análisis más detallados por vaca, incluyendo datos adicionales como frecuencia de movimientos o cambios de postura.

¿Dudas adicionales?

Si persiste alguna duda, el modelo necesita cambios o nos necesita comentar alguna cosa, contáctenos a través del correo electrónico tc.solutions.ia@gmail.com donde nos explique su inquietud para poder brindarle atención personalizada.